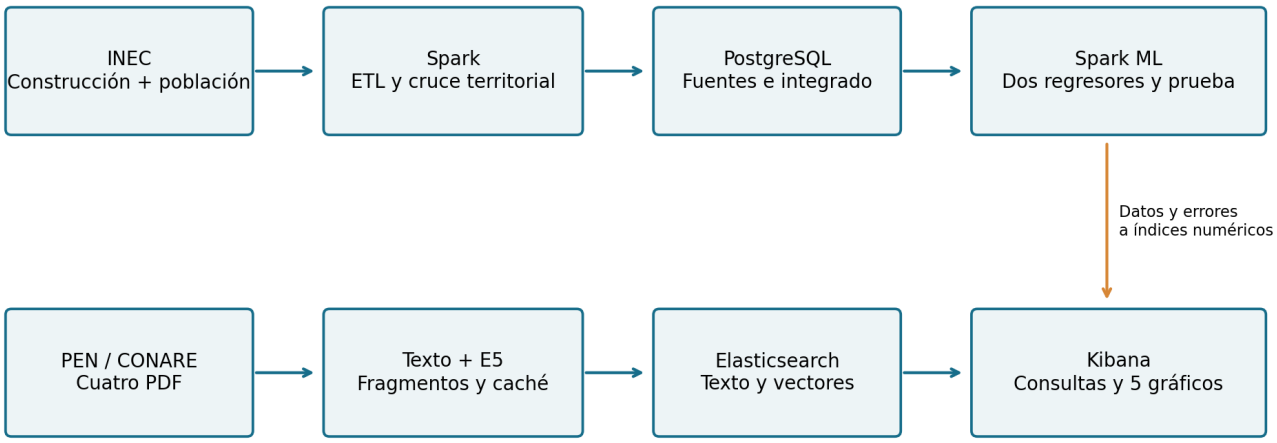
Construcción autorizada y dinámica poblacional

Costa Rica, 2015-2024
Manual de ejecución y documentación

Adrián Rojas Rivera
Versión de revisión: 28 de octubre de 2026

Qué hace el proyecto

Integra construcción y población del INEC por territorio y año, estima el área autorizada del año siguiente con dos regresores de Spark y compara BM25 con búsqueda vectorial en cuatro investigaciones PEN. Los textos son una rama documental independiente, permitida por el enunciado.



Cómo usar este manual

Datos y estructura: páginas 2-3. Ejecución y consultas: 4-5. Modelos: 6-7. Fragmentación y búsquedas: 8-9. Kibana: 10. Validación: 11. Fuentes y entrega: 12.

El código, las configuraciones, las fuentes originales y el notebook ejecutado acompañan este documento. Las cantidades y métricas aquí descritas proceden de la ejecución local del proyecto, no de los ejemplos de clase.

1. Fuentes, extracción y cruce

Fuente	Cobertura y selección
INEC construcción	10 Excel anuales, 2015-2024. Totales cantonales y destinos de obra.
INEC población	Hoja C4 de estimaciones/proyecciones: 84 códigos, 10 años.
PEN / CONARE	Cuatro PDF en español, publicados en 2017, 2018, 2021 y 2023.

Los 15 originales incluidos se verifican contra los hashes SHA-256 de config/fuentes.json. El archivo de población disponible reemplaza la necesidad de acceder a microdatos restringidos; se trabaja con agregados publicados.

Transformación verificable

openpyxl lee el cuadro y localiza encabezados Totales, Construcción, Ampliación y Reparación; la hoja 2016 incluye separadores diferentes. Spark convierte tipos, comprueba claves, agrega y cruza DataFrames. Se conservan archivo, hoja, fila y columnas de origen para rastrear cada valor.

Se extraen 818 totales cantonales y 12 121 filas de destinos. El detalle distingue subtotal_categoria y detalle: sumarlos juntos duplicaría magnitudes. La población produce 840 registros y se verifica total = hombres + mujeres con tolerancia de 0,001.

Armonización territorial

Agrupación	Códigos reunidos
Grecia y Río Cuarto	203 + 216
Puntarenas y Monteverde	601 + 612
Golfito y Puerto Jiménez	607 + 613

Las tres segregaciones se agregan a sus territorios de origen en ambas fuentes antes del join por código y año. Se obtienen 81 agrupaciones y 810 registros. Se comprueban claves únicas, ausencia de pérdidas y conservación del total nacional anual. No se certifica que estas reglas resuelvan cualquier cambio histórico de límites.

Signos y anomalías

Vacíos, -, . y N.D quedan nulos. Se auditan 312 celdas N.D de 2019 y una N aislada en K1413 del Excel 2020 (Coto Brus, Otros destinos). Esta celda se conserva cruda y queda nula con una excepción limitada; no se adivina su conteo. Otros símbolos desconocidos, negativos y conteos fraccionarios detienen la preparación. Evidencia: output/auditoria_signos.json.

2. Esquemas y diccionario

PostgreSQL utiliza el esquema proyecto. Las tablas anteriores al cruce se conservan separadas de sus versiones agrupadas. sql/Esquema.sql contiene tipos, claves y restricciones; doc/Esquemas.md incluye diagramas Mermaid de relaciones y flujos.

Tabla	Grano / clave	Filas
territorios	codigo_agrupacion	81
construccion_cantonal	codigo_canton + anio	818
poblacion_cantonal	codigo_canton + anio	840
destinos_cantonales	id de año, cantón y fila	12 121
construccion_agrupada	codigo_agrupacion + anio	810
poblacion_agrupada	codigo_agrupacion + anio	810
integrado	codigo_agrupacion + anio	810
predicciones	modelo + codigo_agrupacion + anio_objetivo	324

territorios se relaciona por codigo_agrupacion con las dos tablas agrupadas, integrado y predicciones. El join entre las tablas agrupadas utiliza código y año. No se declara una FK falsa entre los códigos originales de fuentes con distinta cobertura.

Campos principales

Campos	Interpretación
obras_total / nuevas / ampliacion / reparacion	Conteos de obras autorizadas, enteros largos.
area_m2 / nueva / ampliacion	Metros cuadrados: obra nueva más ampliada. Reparaciones no agregan área.
valor_*	Miles de colones corrientes; se preservan, sin usarlos como predictores.
poblacion / hombres / mujeres	Personas estimadas/proyectadas; se preservan decimales originales.
area_por_habitante	Área anual / población del mismo año.
anio_datos / anio_objetivo	Último año de atributos y año objetivo, respectivamente.
observado_m2 / prediccion_m2 / error_m2	Magnitudes en m²; error = predicho menos observado.

Un permiso no equivale a una obra terminada ni a una vivienda. Una agrupación armonizada no equivale necesariamente al cantón administrativo actual. Los registros no describen personas individuales.

3. Instalación y ejecución

Requisitos: Docker Desktop activo, Compose v2, conexión inicial y puertos 8894, 9204 y 5604 libres. Se probó con 4 GB de memoria asignada a Docker y 8 CPU. El modelo público ocupa aproximadamente 490 MB; las imágenes y volúmenes requieren espacio adicional. Python y Java vienen en el contenedor.

Abrir la terminal en la carpeta que contiene docker-compose.yaml. Ejecutar en este orden:

```
docker compose up -d --build
docker compose exec -T app python scripts/descargar_modelo.py
docker compose exec -T app python -m pytest -q
docker compose exec -T app python programa.py todo
docker compose exec -T app python scripts/generar_analisis.py
docker compose exec -T app python scripts/ejecutar_notebook.py
```

todo ejecuta preparar, entrenar, embeddings, cargar, buscar, dashboard y verificar, en ese orden. La primera construcción descarga dependencias; no se estima su duración con el tiempo de inferencia del modelo. Si Kibana sigue iniciando, repetir únicamente la etapa dashboard cuando abra su página.

Servicio	Acceso desde el equipo
Jupyter	http://127.0.0.1:8894/lab; token proyecto-local
Kibana	http://127.0.0.1:5604
Elasticsearch	http://127.0.0.1:9204
PostgreSQL	Interno: postgres:5432; DB proyecto; usuario estudiante

El entorno fija Spark 3.5.1, PostgreSQL 16.6 y Elasticsearch/Kibana 8.14.3. requirements.lock.txt registra las versiones Python probadas. Los puertos están ligados a la interfaz local; las credenciales incluidas son de demostración.

Repetir o detener

```
docker compose exec -T app python programa.py verificar
docker compose stop
docker compose up -d
```

Cada etapa puede invocarse por su nombre. Para repetir modelos se necesita preparar; para cargar se necesitan los Parquet, predicciones y embeddings. stop conserva volúmenes. Evitar down -v si se desea preservar los datos cargados. README.md detalla dependencias y recuperación por etapa.

4. Materialización y consultas

La carga conserva fuentes antes y después de cruzarlas. Escribe tablas de preparación por JDBC, sustituye el esquema proyecto dentro de una transacción y vuelve a leer todas las columnas para compararlas con los DataFrames mediante diferencias en ambos sentidos. Recalcula métricas con SQL. Solo reemplaza ese esquema y los índices cp-* de esta instalación.

Índice	Documentos / campos
cp-construccion / cp-poblacion	818 / 840; fuentes cantonales
cp-destinos	12 121; nivel y categoría de destino
cp-integrado / cp-predicciones	810 / 324; agregados y resultados de modelos
cp-texto	298; texto español y metadatos de documento/página
cp-vector	Los mismos 298; añade dense_vector de 384 componentes

Los siete mappings completos están en elastic/. Usan dynamic: strict, códigos keyword, magnitudes numéricas y fecha de tipo date. El texto utiliza analizador spanish; el vector usa coseno y HNSW. IDs estables y conteos se verifican después de bulk y refresh.

fecha es el inicio del año de referencia en Costa Rica, codificado a las 06:00:00Z; no corresponde a cada permiso individual.

Consultar PostgreSQL desde la terminal

```
docker compose exec -T postgres \
  psql -U estudiante -d proyecto < sql/Verificacion.sql

SELECT anio, SUM(area_m2) AS area_nacional
FROM proyecto.integrado
GROUP BY anio ORDER BY anio;
```

Consultar Elasticsearch en Kibana > Dev Tools

```
GET cp-integrado/_count

GET cp-vector/_mapping

GET cp-destinos/_search
{"size": 0, "query": {"term": {"nivel": "subtotal_categoria"}},
 "aggs": {"area": {"sum": {"field": "area_m2"}}}}
```

Las consultas completas del experimento están en elastic/Consultas_Kibana.http. Ejecutar un bloque con el cursor dentro de él mediante el botón triangular o Cmd/Ctrl+Enter. No sumar subtotales y detalle en un mismo agregado.

5. Diseño predictivo

Objetivo: área autorizada nueva y ampliada del año siguiente, en m². Los atributos usan información de años anteriores: área t y t-1, obras t, población t y crecimiento poblacional. No se incorporan textos, valores nominales ni el área del año objetivo a los predictores.

Los niveles y el objetivo se transforman con log1p. La predicción retorna a m² con expm1 y piso cero, definido antes de evaluar. La selección por RMSE se mide en m² originales. VectorAssembler, StandardScaler y regresores se integran en un Pipeline; la escala se aprende dentro de cada fold.



Reajuste final con 2017–2022. Predictores siempre anteriores al año objetivo.

Bloque	Propósito
2017-2021: 405 casos	Cuatro configuraciones por modelo; CrossValidator de tres folds agrupados por territorio, semilla fija.
2022: 81 casos	Validación cronológica para comparar las dos familias requeridas. Persistencia también se informa.
2017-2022: 486 casos	Reajuste final con parámetros ya elegidos.
2023-2024: 162 casos	Prueba reservada. Para 2024 se usan atributos de 2023 sin reajustar el modelo con su objetivo.

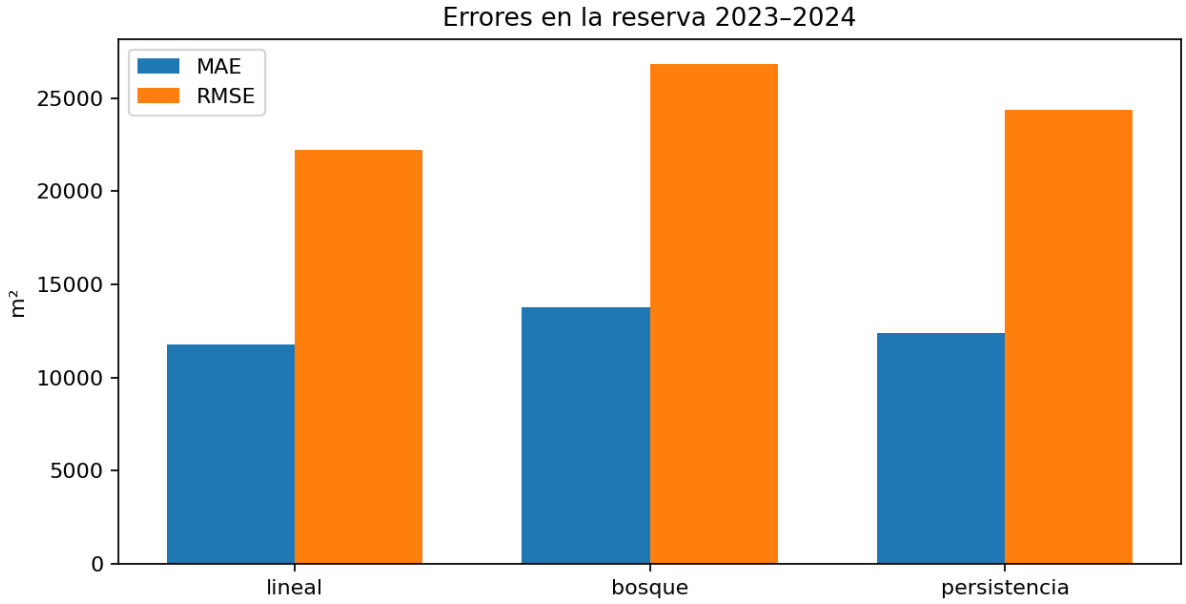
La CV agrupa años de un mismo territorio en el mismo fold; tiene 31, 32 y 18 territorios. Mezcla años de desarrollo: evalúa transferencia entre territorios y no es validación temporal. La reserva posterior aporta la evaluación cronológica. Es una retrospectiva con versiones revisadas, no una simulación exacta de la disponibilidad de cada publicación.

Modelos y selección

Regresión lineal regularizada: regParam ganador 0,01, elasticNetParam 0. Bosque aleatorio: 40 árboles, profundidad 5 y mínimo 4 observaciones por hoja. Se prueban cuatro combinaciones por familia: 24 ajustes de CV, dos reajustes de ganadores y dos finales. Los parámetros, particiones y decisiones previas a la prueba quedan en output/.

6. Resultados de los dos regresores

Prueba 2023-2024	MAE (m²)	RMSE (m²)	Sesgo (m²)
Lineal	11 790,68	22 202,14	-3 780,06
Bosque	13 783,18	26 836,64	-4 730,99
Persistencia	12 410,70	24 385,12	1 445,60



La lineal reduce el MAE 5,00% y el RMSE 8,95% frente a persistencia en la prueba global. El bosque es peor que ambas referencias. Sin embargo, en validación 2022 persistencia había obtenido RMSE 34 378,25 m², frente a 37 627,28 de la lineal y 38 911,73 del bosque. La familia lineal gana entre los dos modelos exigidos; no demuestra que convenga sustituir siempre la referencia simple.

Por qué difieren

La lineal regularizada produce un ajuste suave con pocos datos. El bosque promedia hojas y tiene capacidad limitada para extrapolar extremos; su menor error de entrenamiento y mayor error cronológico son compatibles con un ajuste más específico de desarrollo. En el bosque, las áreas previas reúnen 84,4% de importancia. No son efectos causales de la población.

Ambos subestiman. El ajuste logarítmico y la posterior exponenciación sin corrección pueden contribuir al sesgo; también pueden intervenir cambios temporales y valores extremos. Son explicaciones compatibles, no causas demostradas. No se afinó el modelo después de consultar la prueba.

En 2023 persistencia tiene menor MAE que la lineal, aunque peor RMSE. En 2024 la lineal mejora ambas métricas. output/errores_territorio.csv y doc/Analisis_resultados.md permiten revisar esa heterogeneidad.

7. Fragmentación y embeddings

El feedback del 25/10 acepta las fuentes y pide controlar volumen, dividir textos y respetar los 512 tokens de E5. Se aplica un límite menor, comprobado con el tokenizador real; no se sustituye por una estimación de caracteres.

Comprobación	Resultado
Modelo	intfloat/multilingual-e5-small; revisión fija en config/modelo.json
Originales	4 PDF, 232 páginas
Páginas incluidas	194, con auditoría por documento y página
Fragmentos	298: 285 narrativos y 13 de tabla con maquetación
Límite propio / máximo observado	400 / 397 tokens, incluyendo prefijo y especiales
Solapamiento	Aproximadamente 40 tokens, conservando cobertura
Vectores	384 componentes, finitos y normalizados
Lotes / caché	4 entradas; clave por texto, prefijo, modelo y versiones

Preparación sin truncamiento silencioso

Se separan portadas, referencias y secciones ajenas al alcance; se retiran encabezados repetidos y se unen palabras partidas por guion. Párrafos con glifos privados de fórmulas, alta densidad numérica o sin desarrollo se apartan con evidencia del texto excluido. Se prefieren límites de párrafo y oración; los fragmentos no atraviesan páginas.

El anexo de 2021, páginas PDF 76-82, conserva extracción con maquetación y encabezado contextual. Es texto recuperable con referencia a la página; no son filas relacionales validadas. No atribuir un estado regulatorio municipal ni vigencia actual sin inspeccionar el original.

Tiempos y reutilización

La primera codificación de 298 pasajes tardó 33,94 s en el contenedor; las 14 consultas se miden aparte. No se extrapolan las seis horas del ejemplo de clase ni el rendimiento del piloto macOS. embeddings_inicial.json conserva la primera medición y embeddings.json la más reciente. La caché permite repetir sin inferir los vectores idénticos.

Se emplea passage: para pasajes y query: para preguntas. Título, autor, año, página, URL, hashes y posiciones de caracteres se conservan como metadatos para comprobar la evidencia. Los documentos PEN no se mezclan numéricamente con la serie INEC.

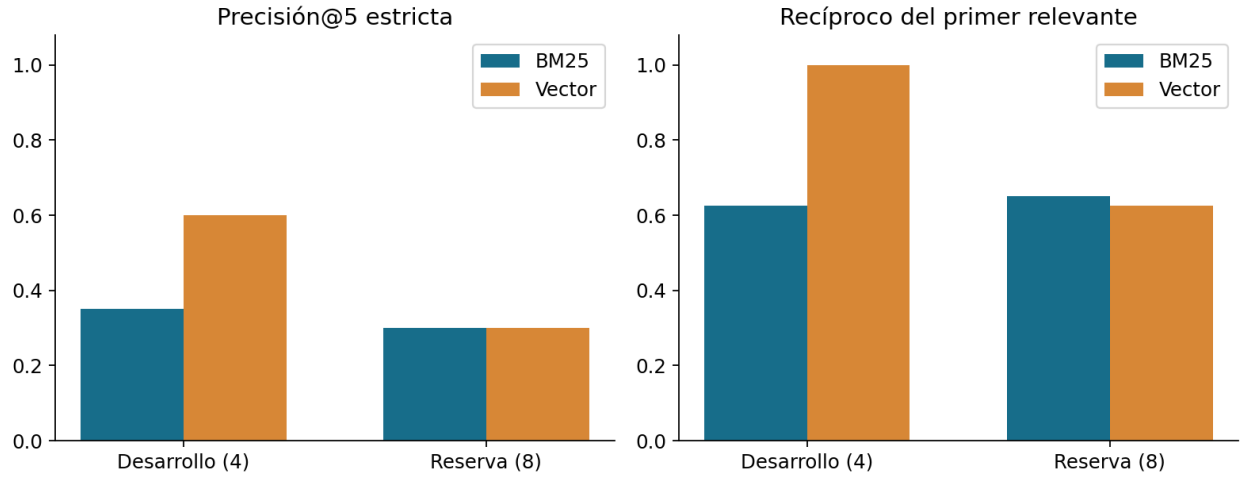
8. Evaluación de búsquedas

BM25 y kNN consultan exactamente los mismos 298 fragmentos y filtros. BM25 usa multi_match sobre texto y titulo con peso 0,2; kNN usa coseno, k=5 y num_candidates=200. Las consultas y mappings se fijaron antes de la ejecución.

Se definieron cuatro consultas de desarrollo, ocho reservadas y dos controles sin respuesta. El pool top5 contiene 110 pares consulta-fragmento; se revisaron ordenados por ID, sin score, método ni posición. Grados: 2 responde directamente, 1 contextual/parcial, 0 no pertinente. Cada juicio tiene justificación en config/relevancia.json.

Grupo	P@5 BM25	P@5 vector	MRR BM25	MRR vector
Desarrollo (4)	0,35	0,60	0,625	1,000
Reserva (8)	0,30	0,30	0,650	0,625
Controles (2)	0,00	0,00	0,000	0,000

Precisión@5 estricta = resultados con grado 2 / 5. MRR = promedio del inverso del rango del primer grado 2, o cero si no aparece. No se reporta recall global: las etiquetas son del pool, no de todo el corpus.



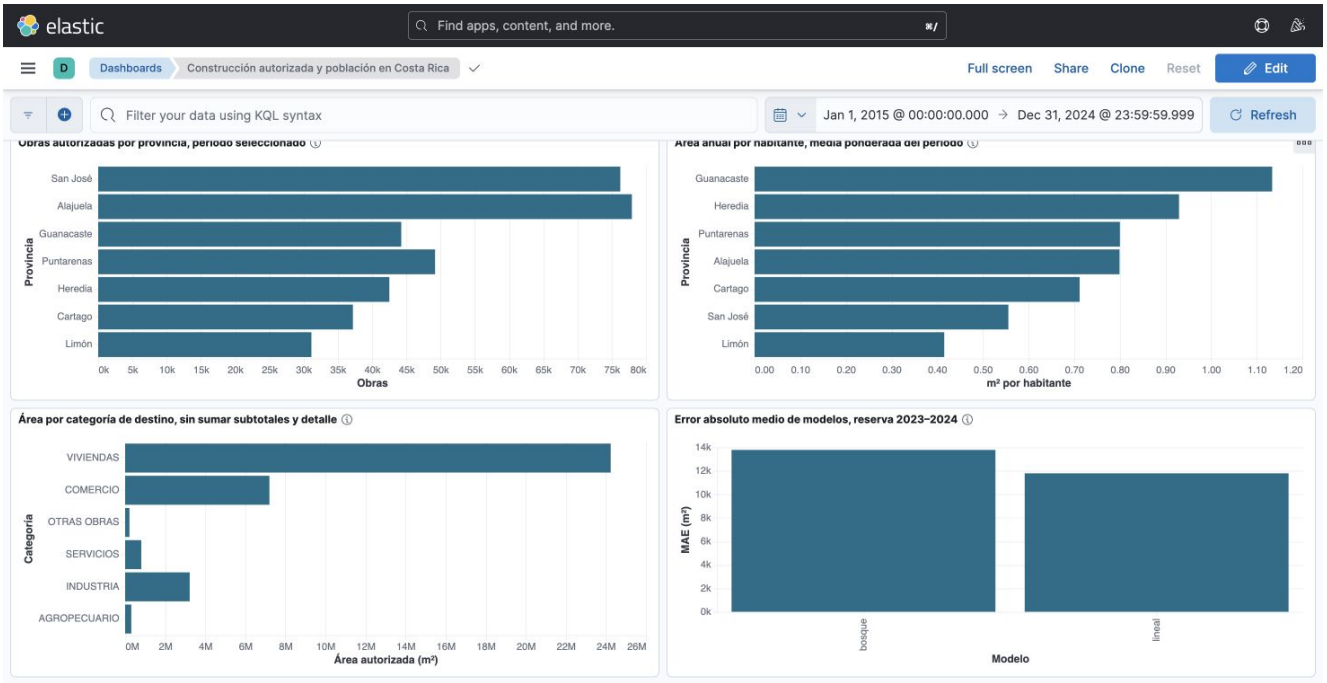
Los vectores ayudan en desarrollo, pero no superan BM25 en reserva. En Q01 el primer relevante pasa de rango 4 a 1 con vectores; en Q03 ambos recuperan primero Pococí, pero también aparecen fragmentos de otro territorio. Q07 no tiene respuesta completa en el top5. En Q11 BM25 ubica primero la respuesta y vectores en cuarto lugar.

Es una evaluación interna pequeña, sin segundo anotador independiente. La diferencia de MRR no demuestra significancia. Los controles sobre Marte y permisos de 2035 devuelven vecinos sin respuesta: no existe abstención calibrada. Latencias de una pasada no son un benchmark concluyente; los fragmentos solapados pueden repetir evidencia de una página.

9. Dashboard y demostración en Kibana

Abrir http://127.0.0.1:5604/app/dashboards#/view/cp-dashboard. El dashboard guarda el intervalo 01/01/2015 a 31/12/2024 en hora de Costa Rica y contiene cinco paneles conectados a los índices reales.

Panel	Índice / cálculo
Área autorizada por año	cp-integrado; suma área, año ascendente
Obras por provincia	cp-integrado; suma de obras del periodo
Área anual por habitante	cp-integrado; suma área / suma población por provincia
Categorías de destino	cp-destinos; solo subtotal_categoria
MAE de modelos	cp-predicciones; media de error absoluto, prueba 2023-2024



Captura de la ejecución local: parte inferior del dashboard, con las categorías sin doble conteo y el error de ambos modelos. La captura superior está en output/Dashboard_completo.png.

Recorrido de 2 minutos y medio

Mostrar la curva anual y describir los permisos. Filtrar una provincia con el buscador KQL (por ejemplo provincia: "Heredia") y volver a limpiar el filtro. Explicar que la razón ponderada no suma ratios ni interpreta población como un flujo. Abrir Dev Tools y ejecutar los bloques Q03 texto y Q03 vector de elastic/Consultas_Kibana.http, conservando el vector completo.

El panel de errores solo contiene 2023-2024; un filtro temporal de otros años lo deja vacío. Si una vista guardada conserva filtros del ensayo, usar Reset o quitarlos. El archivo kibana/dashboard.ndjson exporta siete objetos y puede importarse como respaldo; programa.py dashboard los crea automáticamente.

10. Verificación y diagnóstico

La preparación se comprueba antes de escribir las bases. Quince pruebas automatizadas cubren integridad de originales, cobertura demográfica, encabezados históricos, signos y dominios, claves duplicadas, tres segregaciones, ausencia de información contemporánea del objetivo, historia incompleta, cobertura de fragmentos, fórmulas, caché y niveles de destino.

Evidencia	Comprobación
output/pruebas.log	15 pruebas aprobadas sobre los originales y casos de fallo.
output/etl.json y reconciliacion_nacional.csv	810 integrados; área, obras y valores nacionales conservados.
output/cargas.json	Ocho tablas; relectura JDBC de todas las columnas, diferencias vacías en ambos sentidos.
output/verificacion_bases.json	Conteos de tablas/índices, métricas SQL y mismos IDs/textos en los dos índices.
output/auditoria_signos.json	313 signos no numéricos documentados, sin imputación.
Notebook ejecutado	Salidas, gráficos y consultas reales a ambas bases; sin repetir entrenamiento.

Si algo falla

Docker no responde: iniciar Docker Desktop. **Faltan pesos:** descargar el modelo antes de pytest. **Puerto ocupado:** cambiar el puerto izquierdo en Compose y ajustar el enlace del navegador. **Memoria:** cerrar otros contenedores y mantener lotes pequeños. **Kibana iniciando:** esperar a que abra y repetir dashboard.

Cambió un original: revisar el hash; no desactivar su verificación. **Nuevo símbolo numérico:** inspeccionar la celda y documentar su tratamiento. **Falta un juicio:** leer el nuevo par del pool y justificar su grado antes de calcular métricas. No asignar relevancia según el score.

Archivos regenerables y evidencia

Se incluyen código, configuraciones, 15 originales, análisis, resultados CSV/JSON, vectores, notebook, PDF y presentación. Se excluyen caché de pesos, Parquet intermedios, modelos serializados, archivos temporales y volúmenes. Se regeneran con el procedimiento de la página 4. El paquete tiene un manifiesto de hashes para comprobar sus archivos.

La validación registra límites de alcance: no se afirma apertura nativa en PowerPoint ni evaluación externa de relevancia. Los gráficos y tablas de la presentación son editables; el recorrido se debe ensayar con el entorno iniciado.

11. Fuentes, feedback y entrega

Material docente aplicado

Enunciado project/2026-02-M4-P.md (L4): ETL y pruebas, fuentes antes/después del cruce, dos motores, dos modelos Spark, notebook, análisis, PDF y cinco gráficos. L4, video1908915064.mp4: 00:15:40-00:38:30, entorno/mappings/materialización; 00:38:30-00:50:00, preparación y reutilización de vectores; 00:50:00-01:04:30, comparación de consultas.

L5, video1324764996.mp4, 00:02:40-00:06:10: K-fold también para el proyecto. L5, video1400804262.mp4, 01:29:30-01:34:30: batch; aproximadamente 01:44-01:46: embeddings por grupos. Los tiempos son referencias de consulta, no citas literales. El feedback del 25/10/2026 motiva el control de volumen y fragmentación explicado en la página 8.

Datos y documentación técnica

INEC: población, ficha y serie de C4

Los diez enlaces anuales de construcción y sus hashes exactos se encuentran en config/fuentes.json. Publicaciones PEN/CONARE:

Leonardo Sánchez Hernández (2017). Tendencias de crecimiento en ciudades intermedias. Los casos de San Isidro de El General, Ciudad Quesada y Guápiles

Leonardo Sánchez Hernández (2018). Tendencias y patrones del crecimiento urbano en la GAM, implicaciones sociales, económicas y ambientales y desafíos desde el ordenamiento territorial

Leonardo Sánchez Hernández (2021). Ordenamiento territorial y crecimiento urbano: desafíos e impactos para las ciudades intermedias y la zona marino costera

Eduardo Pérez Molina (2023). Ordenamiento territorial: impactos de la regulación territorial en la Gran Área Metropolitana

Modelo multilingual-e5-small: límites, dimensiones y prefijos

Spark: selección de modelos y CrossValidator

Kibana 8.14: visualizaciones Vega

Cierre de entrega

Entregables 2 y 3: lunes 2 de noviembre de 2026, antes de las 19:00 de Costa Rica. El correo debe seguir el formato de la primera lección e incluir enlace al repositorio y al ZIP/tar.gz en Drive u OneDrive. La presentación dispone de 20 minutos más preguntas. El proyecto no exige un video adicional de siete minutos; ese requisito corresponde a T3.

Revisar los juicios de relevancia, ensayar el guion y comprobar enlaces de entrega. doc/Lista_entrega.md distingue archivos preparados de pasos externos pendientes. Las métricas describen un ejercicio retrospectivo con agregados e investigaciones históricas; no acreditan causalidad, demanda habitacional ni vigencia normativa.